UNIVERSIDADE FEDERAL DO RIO GRANDE DO SUL
INSTITUTO DE FÍSICA

# RELATÓRIO I

GUILHERME MARTINS SOARES
NATÁLIA CAPRA FERRAZZO
RAFAEL CORREA DE LIMA

PORTO ALEGRE, 12 DE FEVEREIRO DE 2022.

# 1. CONJUNTO DE DADOS DISCRETOS

Na primeira etapa deste trabalho, analisamos os dados do arquivo *"dados1.csv".*
A primeira tarefa feita foi plotar um gráfico 2d:

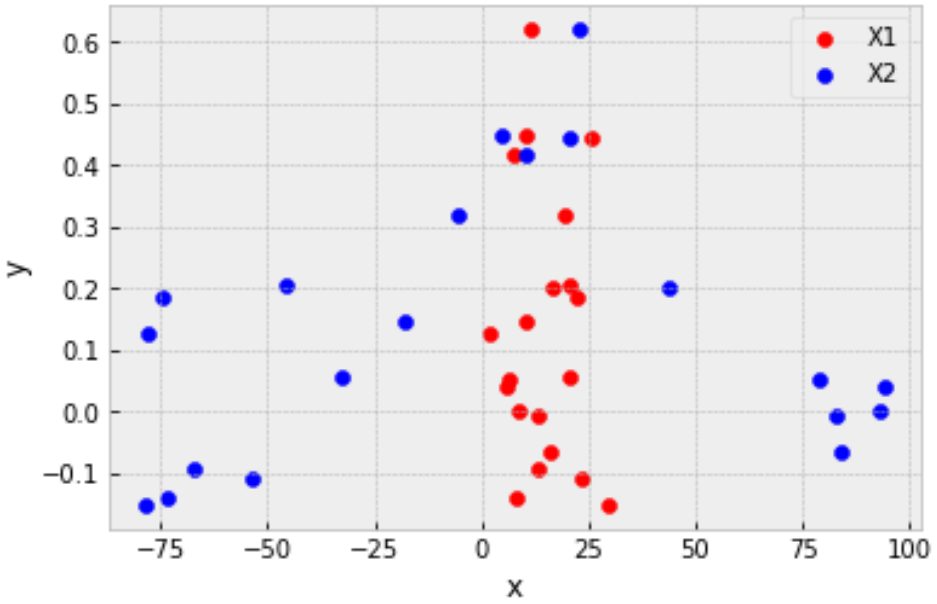


Porém, como nosso conjuntos de dados possui 2 variáveis de entrada e 1 de saída, o ideal é trabalharmos no espaço tridimensional. Sendo assim, um gráfico de dispersão 3D foi gerado:

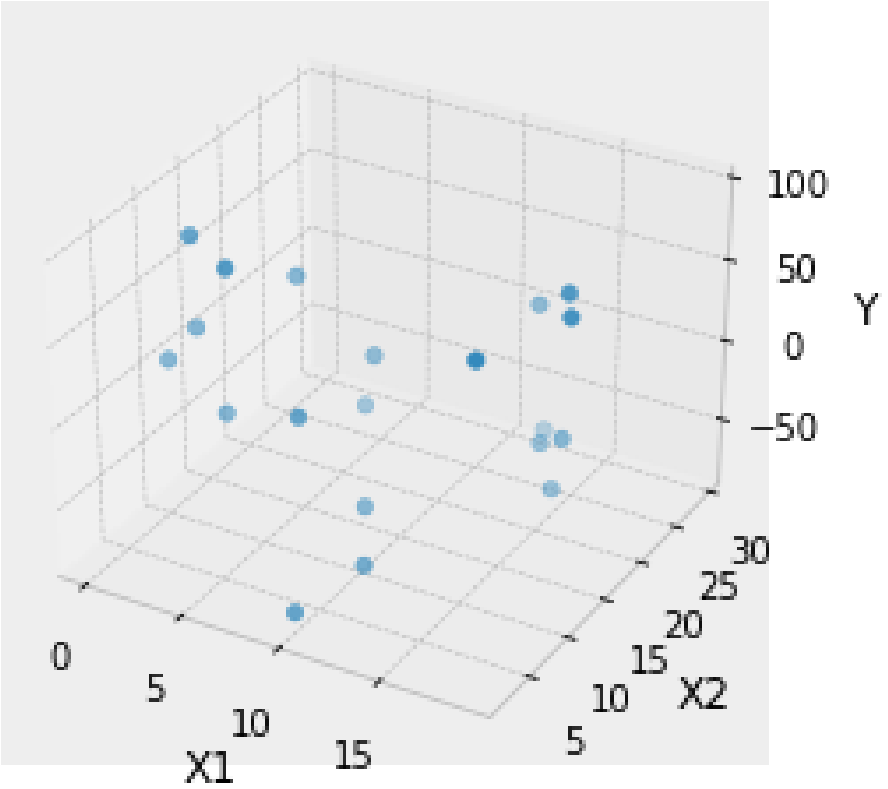

Após, partimos para a análise numérica dos dados. Nessa etapa, foi calculado: contagem de elementos, média, desvio padrão, 25 percentil, mediana (ou 50 percentil), 75 percentil e valores máximos e mínimos presentes no conjunto.

MA

| Índice | X1 | X2 | Y |
|---|---|---|---|
| count | 20 | 20 | 20 |
| mean | 14.5186 | 0.357015 | 0.134921 |
| std | 7.44209 | 62.673 | 0.221084 |
| min | 1.91273 | -78.4076 | -0.15362 |
| 25% | 8.5473 | -56.9657 | -0.0231763 |
| 50% | 13.1523 | -0.338779 | 0.0917986 |
| 75% | 20.5471 | 52.5686 | 0.233993 |
| max | 29.3079 | 93.9483 | 0.622515 |

Após, foi calculada a Matriz de Correlação dos elementos.

| Índice | X1 | X2 | Y |
|---|---|---|---|
| X1 | 1 | -0.322402 | -0.0681102 |
| X2 | -0.322402 | 1 | 0.13042 |
| Y | -0.0681102 | 0.13042 | 1 |

Para gerar uma função de fit dos dados, poderia ser utilizado a função *spopt* da biblioteca *scipy*. Sem a utilização de bibliotecas, a implementação de um fit 3D é consideravelmente complexa. Como o objetivo deste trabalho era não utilizar bibliotecas prontas, não conseguimos chegar a nenhum resultado de função satisfatório. Analisando visualmente os gráficos, um chute do grupo seria a função *"cela" (parabolóide hiperbólico)*: $y = x_1^2 - x_2^2$.

## CÓDIGO-FONTE

```
#!/usr/bin/env python3
# -*- coding: utf-8 -*-

import numpy as np
import pandas as pd
import matplotlib.pyplot as plt

dados1 = pd.read_csv("dados1.csv")

#dados1.plot.scatter("X1", "Y")

plt.scatter(dados1["X1"], dados1["Y"], label='X1', color='#f00')
plt.scatter(dados1["X2"], dados1["Y"], label='X2', color='#00f')

plt.legend()
plt.xlabel("x")
plt.ylabel("y")
plt.show()

describe = dados1.describe()
corr = dados1.corr()

df = pd.read_csv('dados1.csv', parse_dates=True)

threedee = plt.figure().gca(projection='3d', )

threedee.scatter(df.index, df['X1'], df['X2'])
threedee.set_xlabel('X1')
threedee.set_ylabel('X2')
threedee.set_zlabel('Y')
plt.show()
```

## 2. CONJUNTO DE DADOS CATEGÓRICOS

Para plotar o conjunto categórico, primeiro separou-se o dataset por categoria e gerou-se um gráfico scatter:

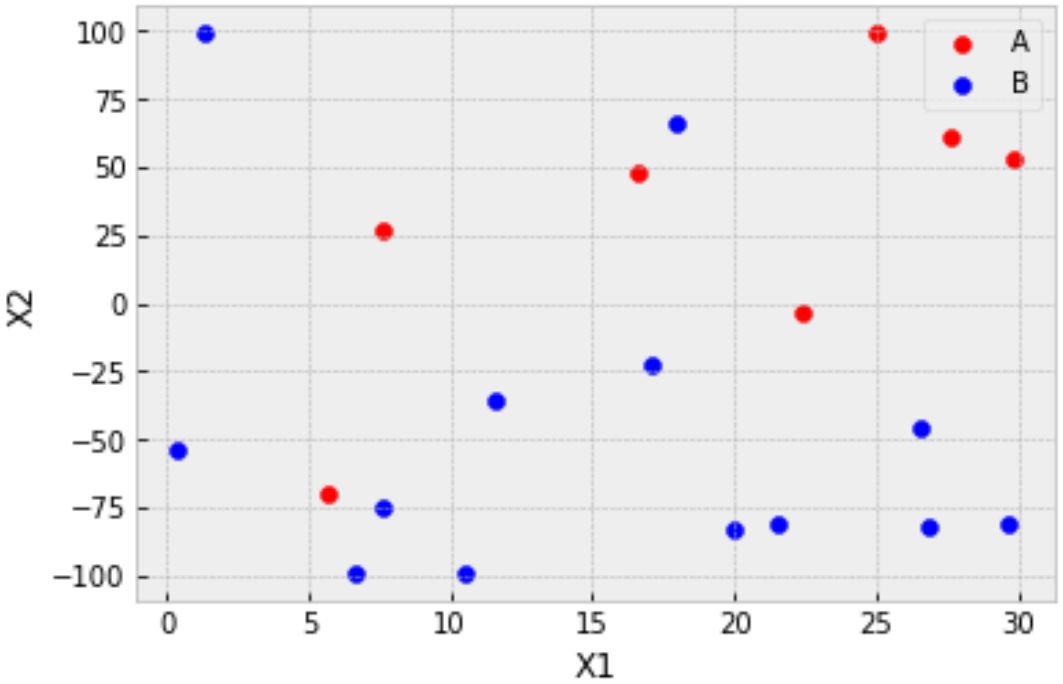


Da análise numérica, novamente retiramos as mesmas métricas:

| Índice | X1 | X2 |
|---|---|---|
| count | 20 | 20 |
| mean | 16.6261 | -18.8465 |
| std | 9.6059 | 68.9943 |
| min | 0.410093 | -99.4988 |
| 25% | 7.60453 | -80.8836 |
| 50% | 17.5495 | -40.8352 |
| 75% | 25.4111 | 49.4712 |
| max | 29.8222 | 99.6916 |

Para este conjunto, o ideal seria utilizar uma clusterização KNN, que poderia ser obtida através da função *KMeans* da biblioteca *scikit-learn*. Para implementar artesanalmente, o algoritmo teria certa complexidade, que foge ao escopo deste relatório.

## CÓDIGO-FONTE

```
#!/usr/bin/env python3
# -*- coding: utf-8 -*-

import numpy as np
import pandas as pd
import matplotlib.pyplot as plt

dados2 = pd.read_csv("dados2.csv")

#dados1.plot.scatter("X1", "Y")
dados_A = dados2[dados2[" Categoria "] == "A"]
dados_B = dados2[dados2[" Categoria "] == "B"]
plt.scatter(dados_A["X1"], dados_A[" X2"], label='A', color='#f00')
plt.scatter(dados_B["X1"], dados_B[" X2"], label='B', color='#00f')
plt.legend()
plt.xlabel("X1")
plt.ylabel("X2")
plt.show()

describe = dados2.describe()
corr = dados2.corr()
```