TERMODINÂMICA E MECÂNICA ESTATÍSTICA

BACHARELADO EM ENGENHARIA FÍSICA

Método de Monte Carlo

Autora:
NATÁLIA CAPRA FERRAZZO *(00243977)*

Professor:
Prof. Dr. David MÖCKLI

Porto Alegre
2021

Primeira Lei: Um robô não pode ferir um ser humano ou, por omissão, permitir que um ser humano sofra algum mal. Segunda Lei: Um robô deve obedecer as ordens que lhe sejam dadas por seres humanos, exceto nos casos em que tais ordens contrariem a Primeira Lei. Terceira Lei: Um robô deve proteger sua própria existência desde que tal proteção não entre em conflito com a Primeira e Segunda Leis

(ASIMOV, Isaac, 1950)

RESUMO

O método de Monte Carlo é um método computacional que utiliza números aleatórios e estatísticas para resolver problemas. Atualmente, muitos problemas numéricos em Finanças, Engenharia e Estatística são resolvidos com esse método. O interesse nesse estudo é aplicar a técnica para calcular integrais e para simular eventos discretos. Para os casos em que as integrais não podem ser calculadas explicitamente, para o cálculo de integrais multidimensionais e para calcular integrais impróprias pode-se utilizar simulação de Monte Carlo. A simulação de um modelo probabilístico consiste na geração de mecanismos estocásticos e, em seguida, na observação do fluxo resultante do modelo ao longo do tempo. Dependendo das razões para a simulação, haverá certas quantidades de interesse que se quer determinar. No entanto, a evolução do modelo ao longo do tempo frequentemente envolve uma estrutura lógica complexa de seus elementos. Desse modo, nem sempre é evidente como acompanhar essa evolução de modo a determinar estas quantidades de interesse. Uma estrutura geral construída em torno da ideia de "eventos discretos" foi desenvolvida para ajudar a seguir um modelo ao longo do tempo e determinar as quantidades relevantes de interesse. A simulação baseada nesta estrutura é muitas vezes chamada simulação de eventos discretos. Assim, o estudo do método de Monte Carlo é uma ótima alternativa para tais simulações e requer conhecimento de diferentes áreas do conhecimento: Probabilidade, para descrever processos e experimentos aleatórios; Estatística para analisar os dados; Ciência da Computação para implementação eficiente de algoritmos e Programação Matemática para formular e resolver problemas de otimização. Além, é claro, de conhecimentos físicos para aplicações em Mecânica Estatística.

Palavras-chave: Método de Monte Carlo. Eventos Discretos. Simulação. Mecânica Estatística

1 INTRODUÇÃO

Em 1738, o físico e matemático suíço Daniel Bernoulli publicou seu livro Hydrodynamica, que lançou as bases para a teoria cinética dos gases. Neste trabalho, Bernoulli postulou o argumento de que os gases consistem de um grande número de moléculas que se movem em todas as direções, que o impacto delas sobre uma superfície causa a pressão e que a temperatura do gás está relacionada à energia cinética dessas moléculas. (WIKIPÉDIA, a. e. l., 2020)

Fazer predições de maneira *determinística* sobre esse tipo de sistema é, por definição, algo extremamente difícil, quiçá impossível[1]. Para contornar essa dificuldade, surge, em 1870, a ideia de utilizar métodos *probabilísticos* para determinar as propriedades de sistemas físicos complexos; o que, mais tarde, ficaria conhecido como Mecânica Estatística.

A Mecânica Estatística usa um conjunto de cálculos probabilísticos para a ocorrência dos diferentes microestados e atribui uma série de vínculos matemáticos, como a hipótese de ergodicidade, para, assim, chegar a determinação do estado macroscópico do sistema.

Embora alguns problemas em mecânica estatística possam ser resolvidos analiticamente por meio de aproximações e expansões, as pesquisas mais atuais utilizam o poder de processamento de computadores modernos para simular ou aproximar soluções. Uma abordagem comum para problemas estatísticos é usar uma simulação de *Monte Carlo* para produzir uma ideia da dinâmica de um sistema complexo.(WIKIPÉDIA, a. e. l., 2018)

Este método computacional se baseia em um grande número de amostragens aleatórias para a obtenção de um resultado numérico. Aplicando-se este algoritmo à equação física que descreve o sistema, pode-se determinar suas grandezas macroscópicas, como a quantidade de energia, a pressão e a temperatura.

É especialmente interessante notar a eficiência do método aplicado a fenômenos caóticos que, *a priori*, não se imagina serem possíveis de calcular-se desta maneira. Como exemplo, pode-se citar o recente estudo publicado na revista *Nature* onde utilizou-se o método de Monte Carlo para fazer predições sobre o número de infectados por COVID-19 e chegou-se a um resultado muito próximo ao efetivado. O método também é bastante utilizado, por exemplo, para predição de valores de ativos no mercado de ações financeiras.

[1] A ordem de grandeza da quantidade de partículas de gás em uma sala qualquer é de 10^{23}. Além de ser extremamente oneroso, calcular a trajetória desse número de partículas seria desinteressante e irrelevante fisicamente.

2 O MÉTODO

Em termos mais gerais, o método de Monte Carlo é uma abordagem estatística para calcular integrais usando posições aleatórias, as amostras, cuja distribuição é cuidadosamente escolhida. Nesta seção, será discutido como obtêm-se essas amostras, como processá-las a fim de avaliar aproximadamente a integral em questão, e como obter bons resultados com o mínimo de amostras possível.

2.1 Definição

Embora não haja consenso sobre como Monte Carlo deve ser definido, Sawilowsky[1] distingue entre uma simulação, um método de Monte Carlo e uma simulação de Monte Carlo: uma simulação é uma representação fictícia da realidade, um método de Monte Carlo é uma técnica que pode ser usada para resolver um problema matemático ou estatístico e uma simulação de Monte Carlo usa amostragem repetida para obter as propriedades estatísticas de algum fenômeno (ou comportamento).

> Simulação: O desenho de uma variável uniforme pseudoaleatória do intervalo [0,1] pode ser usado para simular o lançamento de uma moeda: Se o valor for menor ou igual a 0,50 designe o resultado como cara, mas se o valor for maior de 0,50 designa o resultado como coroas. Esta é uma simulação, mas não uma simulação de Monte Carlo.
>
> Método de Monte Carlo: colocar uma caixa de moedas sobre a mesa e depois calcular a proporção de moedas que caem cara versus coroa é um método de Monte Carlo para determinar o comportamento de lançamentos repetidos de moeda, mas não é uma simulação.
>
> Simulação de Monte Carlo: Desenho de um grande número de variáveis uniformes pseudo-aleatórias do intervalo [0,1] de uma vez, ou uma vez em vários momentos diferentes, e atribuindo valores menores ou iguais a 0,50 como cara e maior que 0,50 como coroa, é uma simulação de Monte Carlo do comportamento de jogar uma moeda repetidamente.

De acordo com Kalos e Whitlock (KALOS MALVIN H.; WHITLOCK, 2008), tais distinções nem sempre são fáceis de manter. Por exemplo, a emissão de radiação de átomos é um processo estocástico natural. Ele pode ser simulado diretamente, ou seu comportamento médio pode ser descrito por equações estocásticas que podem ser resolvidas usando métodos de Monte Carlo. "Na verdade, o mesmo código de computador pode ser visto simultaneamente como uma 'simulação natural' ou como uma solução das equações por amostragem natural.".

A ideia principal por trás desse método é que os resultados são calculados com base em amostragem aleatória repetida e análise estatística. A simulação de Monte Carlo é, na verdade, experimentações aleatórias, no caso, os resultados dessas experiências não são bem conhecidos. As simulações de Monte Carlo são tipicamente caracterizadas por muitos

[1] Shlomo S. Sawilowsky foi professor de estatística educacional e Distinguished Faculty Fellow na Wayne State University em Detroit, Michigan, onde recebeu prêmios de ensino, orientação e pesquisa.(WIKIPEDIA CONTRIBUTORS, 2021)

parâmetros desconhecidos, muitos dos quais são difíceis de obter experimentalmente. Os métodos de simulação de Monte Carlo nem sempre requerem números verdadeiramente aleatórios para serem úteis (embora, para algumas aplicações, como testes de primalidade, a imprevisibilidade seja vital).(WIKIPÉDIA, 2020)

2.2 A Agulha de Buffon

Uma variante inicial do método de Monte Carlo foi desenvolvida para resolver o problema da agulha de Buffon, no qual Pi (π) pode ser estimado jogando agulhas em um piso feito de tiras equidistantes paralelas.

> *Suponha que temos um piso feito de tiras paralelas de madeira, cada uma com a mesma largura, e colocamos uma agulha no chão. Qual é a probabilidade de a agulha cruzar uma linha entre duas tiras? (KRAUTH, 2006)*

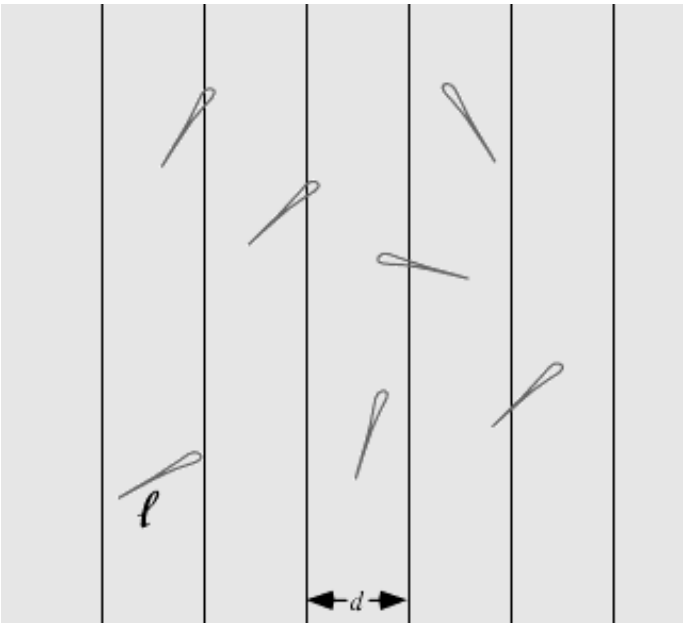

Figura 1 – Ilustração do problema da Agulha de Buffon.

Este problema pode ser resolvido usando geometria integral. A solução para a probabilidade procurada P, no caso em que o comprimento da agulha l não é maior que a largura d das tiras, é

$$P = \int_0^{\phi} \frac{l.sin\theta}{d} \frac{d\theta}{\phi}$$

onde ϕ e θ são angulos genéricos.

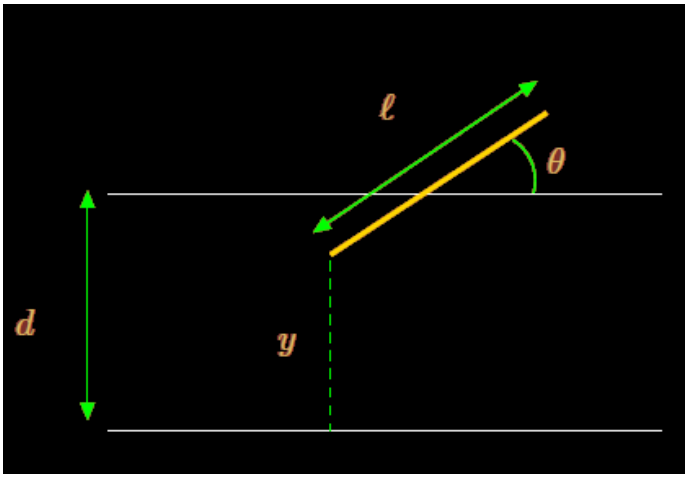

Figura 2 – Esquemática do problema.

Resolvendo a equação anterior, tem-se:

$$P = \int_0^{\phi} \frac{l.sin\theta}{d} \frac{d\theta}{\phi} = \frac{l - l.cos\phi}{d.\phi}$$

Como ϕ é um ângulo qualquer, pode-se escolhê-lo apropriadamente para que $cos(\phi) = 0$. Assim:

$$P = \frac{l}{d.\phi}$$

Com isso, basta que se jogue N agulhas e observe o número n de agulhas que acertam uma das linhas entre as tiras. Sabemos que:

$$P = \frac{n}{N}$$

Logo

$$\frac{n}{N} = \frac{l}{d.\phi}$$

Isolando a angulo ϕ, tem-se

$$\phi = \frac{l.N}{n.d}$$

Fazendo simulação com n e N suficientemente grandes, pode-se notar que o angulo ϕ se aproxima de $\frac{\pi}{2}$. Na figura abaixo, observa-se uma simulação onde obtêm-se valores aproximados de π e variações de uma série de simulações com N indo de 500 até 100.000 arremessos.

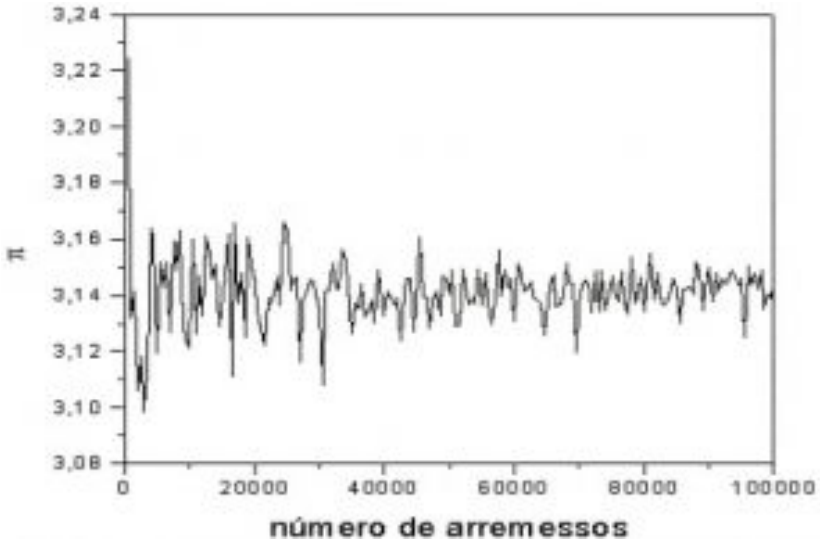

Figura 3 – Gráfico com diferentes valores para N .

3 O EXEMPLO DE KRAUTH

Uma variação do método anterior para calcular o valor aproximado de π é o que Werner Krauth exemplifica no primeiro capítulo de seu livro, Statistical Mechanics - Algorithms and Computations:

> A amostragem direta é exemplificada por um jogo divertido que podemos imaginar crianças brincando nas praias de Mônaco. Na areia, elas primeiro desenham um grande círculo envolto por um quadrado, de modo que seus centros coincidam e que o lado l do quadrado seja igual ao diâmetro do círculo (conforme figura). Elas então jogam pedras aleatoriamente. Cada pedra que cai dentro do quadrado constitui uma tentativa, e pedras dentro do círculo são contadas como "acertos".
>
> Ao manter o controle do número de tentativas e acertos, as crianças realizam um cálculo de Monte Carlo de amostragem direta: a proporção de acertos para tentativas é próxima à proporção das áreas do círculo e do quadrado, ou seja, $\pi/4$. *(Tradução livre)* (KRAUTH, 2006)

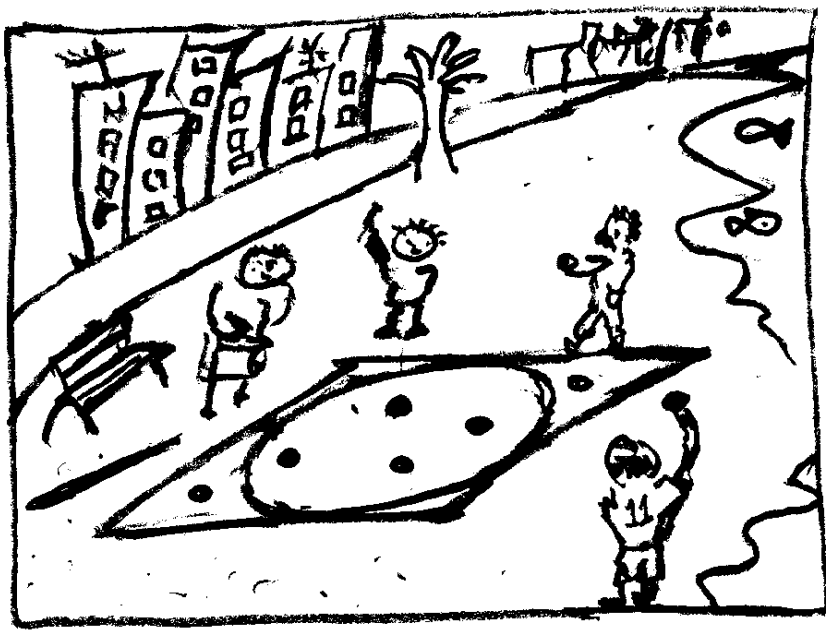

Figura 4 – *"Crianças calculando a aproximação do número π na praia de Monte Carlo."*

As simulações computacionais deste jogo proposto por Krauth, podem ser implementadas facilmente através do script, em linguagem python, a seguir: (PEASE, 2018)

```
import numpy as np
import matplotlib.pyplot as plt
n = 1000
x = np.random.rand(n,2)
inside = x[np.sqrt(x[:,0]**2+x[:,1]**2) < 1]
estimate = 4*len(inside)/len(x)
print ('Estimate of pi: {}'.format(estimate))
plt.figure(figsize=(8,8))
plt.scatter(x[:,0], x[:,1], s= .5, c='red')
plt.scatter(inside[:,0], inside[:,1], s=.5, c='blue')
plt.show()
```

Nesta simulação, aumentando o número de jogadas, pode-se perceber que a estimativa de π fica cada vez mais próxima do número exato.

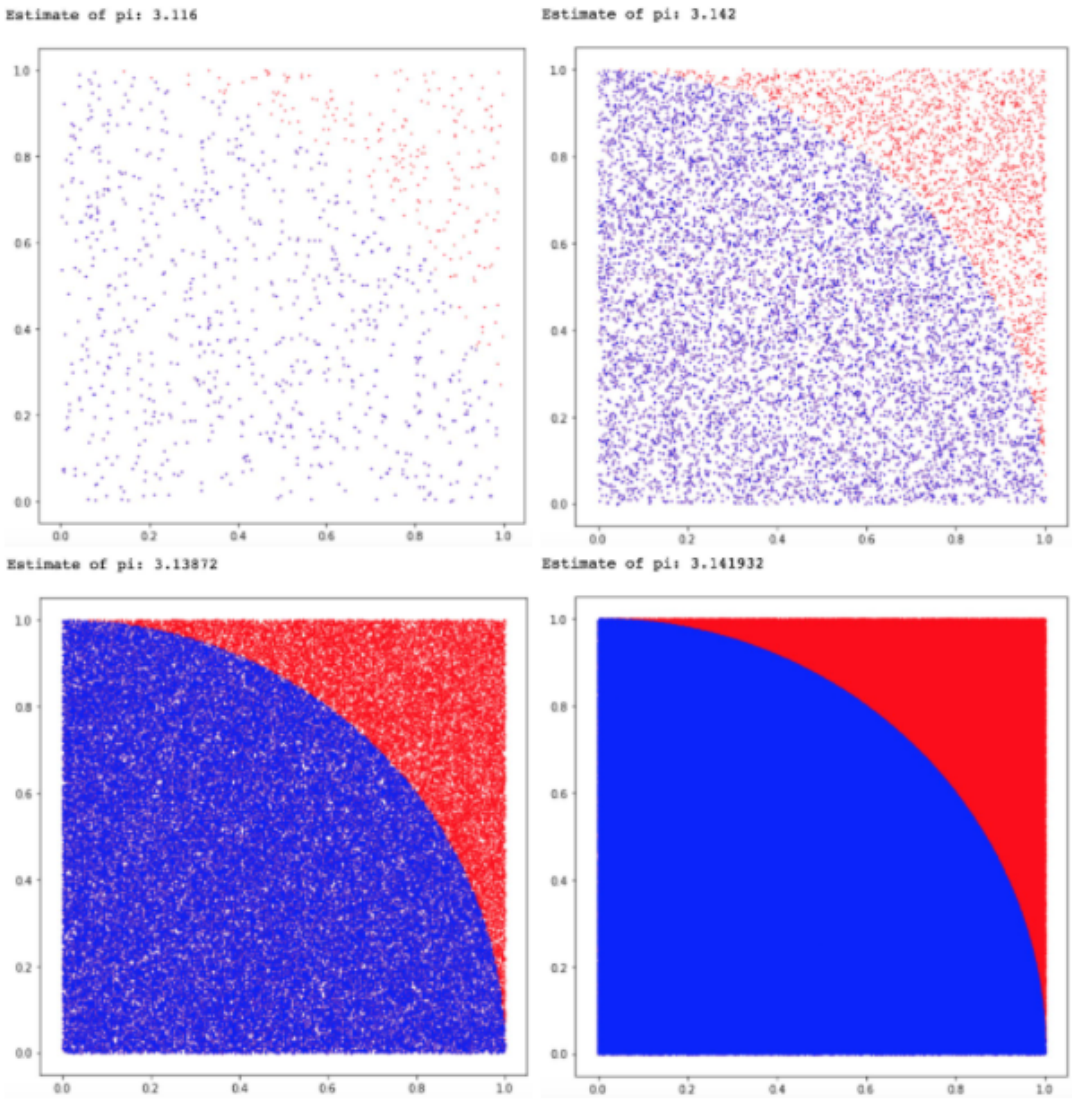

Figura 5 – *"Plots para n=1, n=10, n=100.000, e, finalmente, n= 1.000.000"*

4 CADEIA DE MARKOV

A cadeia de markov é um processo estocástico caracterizado por seu estado futuro depender apenas do seu estado atual, sendo que os estados passados não influenciam no estado futuro. O nome cadeia de markov foi dado em homenagem ao matemático russo Andrey Markov (WIKIPÉDIA, 2021).

Para ilustrar esse processo, pode-se utilizar o exemplo anterior, porém, fazendo algumas modificações:

Agora, as crianças não jogam as pedras ao acaso. Elas partem com 1 pedra de um lugar aleatório dentro da área do quadrado e, uma vez cada uma, movem a pedra em uma direção aleatória, por uma distância fixa x. Abaixo é ilustrado um pedaço da área do jogo. Inicialmente a pedra está em t, depois é deslocada para t+1, depois para t+2 e assim por diante.

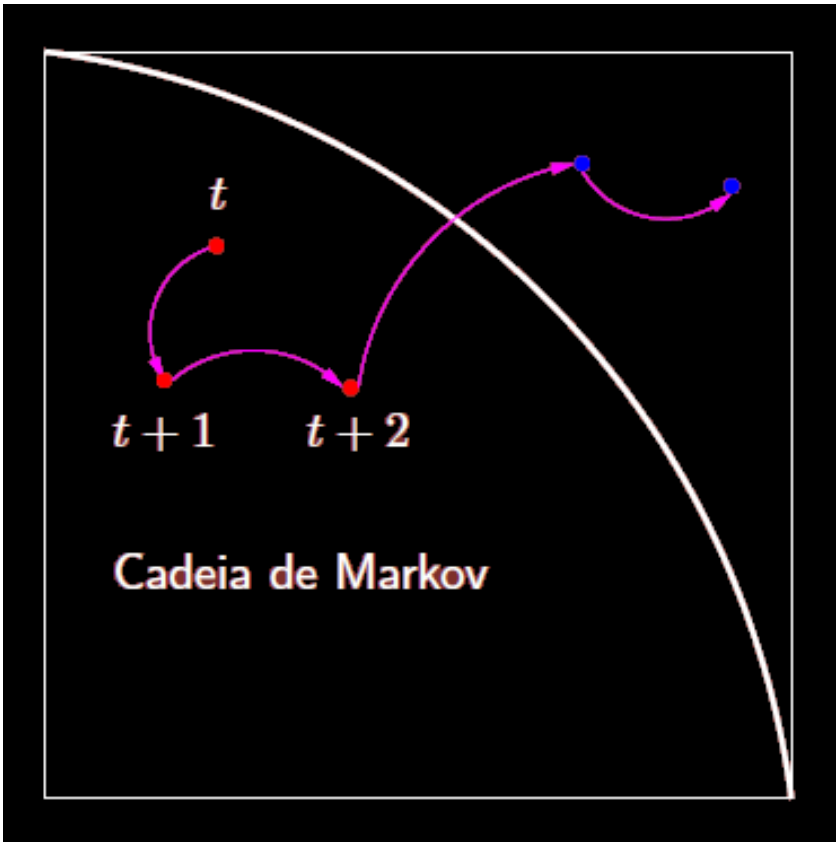

Figura 6 – *Cadeia de Markov*

Com isso, tem-se um problema: O que acontece se a pedra estiver em um canto e uma criança escolher um local para fora da área válida?

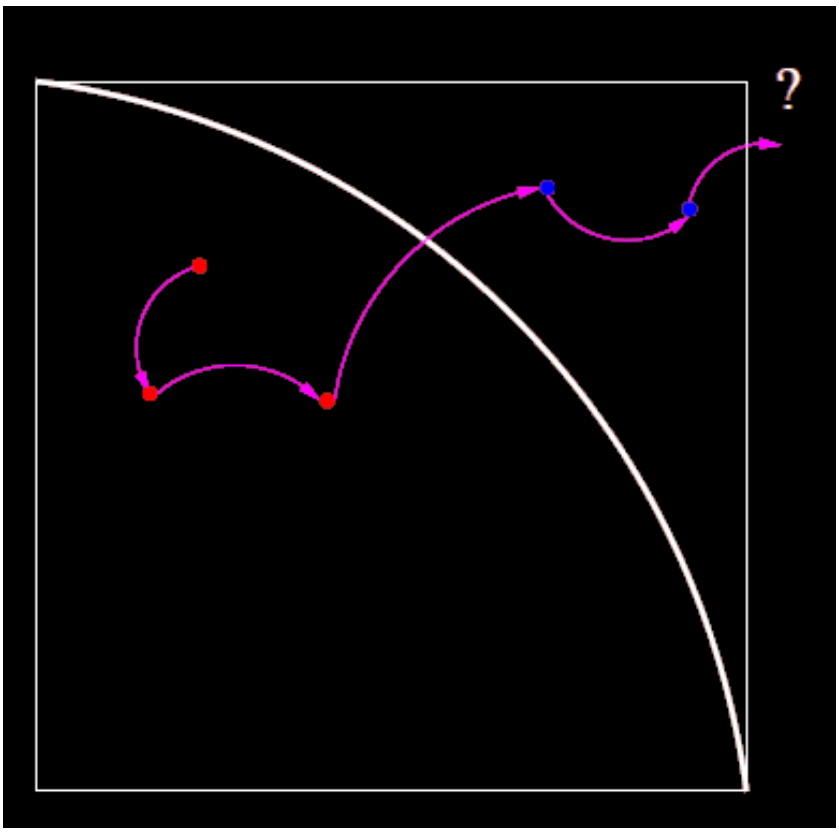

Figura 7 – *Ilustração sobre jogada fora da área "válida".*

A solução mais óbvia poderia ser definir que saltos que saem da área do quadrado não são aceitos. Fazendo essa simulação, obtêm-se o gráfico abaixo.

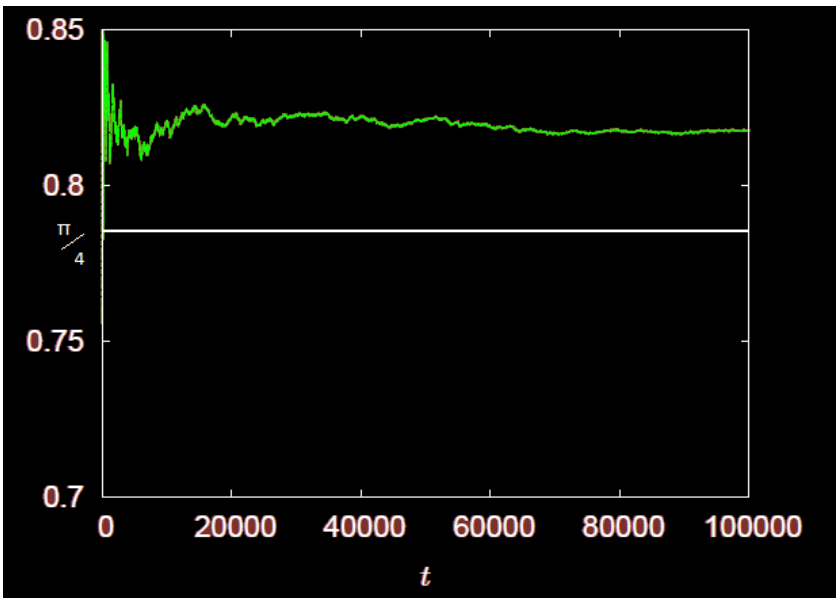

Figura 8 – *Gráfico com valor de $\pi/4$ e o valor aproximado do método.*

Pode-se observar que esta "aproximação"ficou longe do ideal.

4.1 Empilhando as Pedras

O que deve ser feito para que a aproximação seja relativamente boa, é o método de empilhamento. Cada vez que a pedra iria para um lugar fora do escopo do experimento, conta-se o ponto em que ela está atualmente novamente, e segue-se com a jogada da próxima criança. Caso a nova jogada resulte novamente em um lugar fora da área, mais uma vez é contado o lugar em que ela está, e assim por diante, até que um lugar "válido"seja jogado. Quando esse procedimento é feito, a simulação resulta no valor esperado.

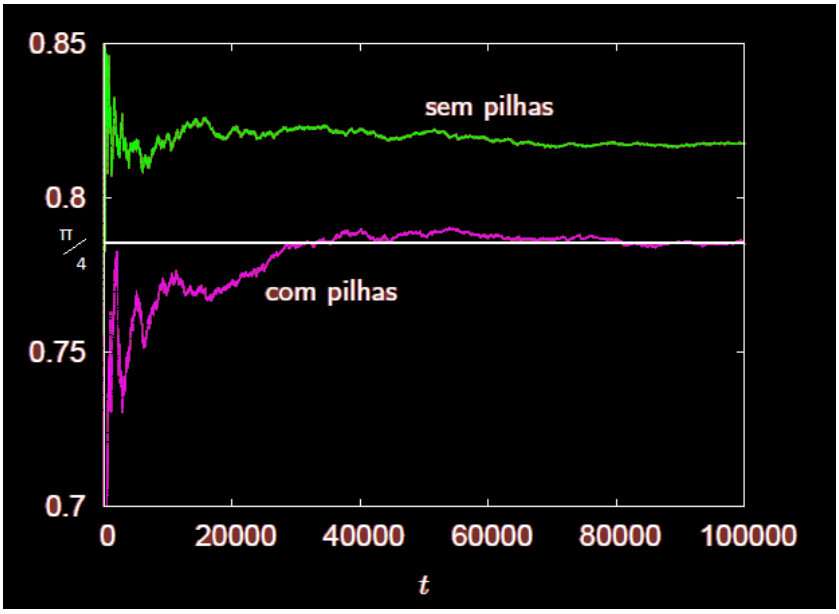

Figura 9 – *Gráfico com valor de $\pi/4$ e o valor aproximado do método sem pilhas e com pilhas.*

A explicação do porquê isso ocorre não é trivial e está detalhada na seção 1.1.4 do livro do Krauth. (KRAUTH, 2006)

5 O MÉTODO APLICADO À MECÂNICA ESTATÍSTICA

Problemas que envolvem variáveis que não controlamos podem ser descritos como processos aleatórios. Logo, simulações de Monte Carlo, que têm por base a produção de números (pseudo)aleatórios, podem ser aplicadas de maneira natural a Mecânica Estatística.

5.1 Função de Partição

Como visto no livro texto desta disciplina, (FLIESSBACH; PROVIDÊNCIA JR, 2000), a função de partição de um sistema é uma grandeza que descreve as propriedades estatísticas de um sistema em equilíbrio. Dela, pode-se extrair informações extremamente relevantes sobre o sistema observado. Os valores esperados são determinados pela distribuição de Boltzmann:

$$\langle Q \rangle = \frac{\sum_\mu Q_\mu e^{-\beta E_\mu}}{\sum_\mu e^{-\beta E_\mu}} \equiv \sum_\mu Q_\mu P_\mu$$

$$P_\mu = \frac{e^{-\beta E_\nu}}{\sum_\mu e^{-\beta E_\nu}} \equiv \frac{e^{-\beta E_\nu}}{Z}$$

$$\beta = (k_B T)^{-1}$$

Logo, para obter exatamente qualquer valor esperado, basta calcular a média ponderada da quantidade correspondente sobre todas as configurações μ.

Imagine que este sistema é composto por $N = 100$ partículas. Logo, tem-se 2^{100} estados possíveis desse sistema. É aí que entra o Método de Monte Carlo.

Sendo impossível considerar todas as configurações, podemos amostrá-las com uma certa distribuição de probabilidades p_μ e estimar os valores esperados segundo

$$\langle Q \rangle = \frac{\sum_{i=1}^{M} Q_{\mu_i} p_{\mu_i}^{-1} e^{-\beta E_{\mu_i}}}{\sum_{i=1}^{M} p_{\mu_i}^{-1} e^{-\beta E_{\mu_i}}}$$

p_μ não pode ser uniforme, porque o peso de Boltzmann diz que configurações com energia muito alta raramente são visitadas em um sistema real. Deve-se escolher p_μ de modo a emular na simulação o que a natureza faz: estados são visitados com probabilidade proporcional ao seu peso de Boltzmann.

$$p_\mu = P_\mu = \frac{e^{-\beta E_\mu}}{Z}$$

$$Q_M = \frac{1}{M} \sum_{i=1}^{M} Q_{\mu_i}$$

Ao invés de escolher ao acaso configurações de acordo com p_μ, é mais eficiente percorrer uma cadeia de configurações que reproduza ao longo do tempo a distribuição de Boltzmann. A estratégia é passar de uma configuração à seguinte na cadeia pela escolha de probabilidades de transição adequadas. A implementação mais simples dessa ideia é o algoritmo de Metropolis***ref: a probabilidade de transição entre uma configuração e outra é

$$w(\mu \to \nu) = \begin{cases} 1, & \text{se } E_\nu < E_\mu \\ e^{-\beta(E_\nu - E_\mu)}, & \text{se } E_\nu \geq E_\mu \end{cases}$$

Com essa escolha, o algoritmo é ergódico e satisfaz o balanço detalhado

$$p_u w(\mu \to \nu) = p_\nu w(\nu \to \mu)$$

6 O MÉTODO APLICADO À SISTEMAS IMPROVÁVEIS

Em meio a caótica pandemia de COVID-19 que abalou o mundo em 2020, alguns artigos interessantes surgiram: simulações de Monte Carlo aplicadas ao sistema de dinâmica de surto e propagação chegaram a valores próximos aos efetivados.

Em seu artigo publicado na revista Nature, Xie (XIE, 2021), seguindo uma abordagem com modelo de processo estocástico, fez uma simulação de Monte Carlo que foi desenvolvida para representar a dinâmica de propagação de COVID-19.

Primeiro, foram examinados vários desempenhos esperados (propriedades teóricas) do modelo de simulação assumindo uma série de cenários definidos arbitrariamente. Os estudos de simulação foram realizados nos dados reais do COVID-19 relatados (no período de 1 de março a 1 de maio) para a Austrália e o Reino Unido. Dado que o número inicial de casos ativos de infecção COVID-19 foi de cerca de 10 para ambos os países, o modelo estimou que o número de casos ativos atingiria o pico por volta de 29 de março na Austrália ($\approx$ 1.700 casos) e por volta de 22 de abril no Reino Unido ($\approx$ 22.860 casos). Em última análise, o total de casos confirmados poderia somar 6.790 para a Austrália em cerca de 75 dias e 206.480 para o Reino Unido em cerca de 105 dias. Os resultados dos números de reprodução estimados do COVID-19 foram consistentes com o que foi relatado na literatura.

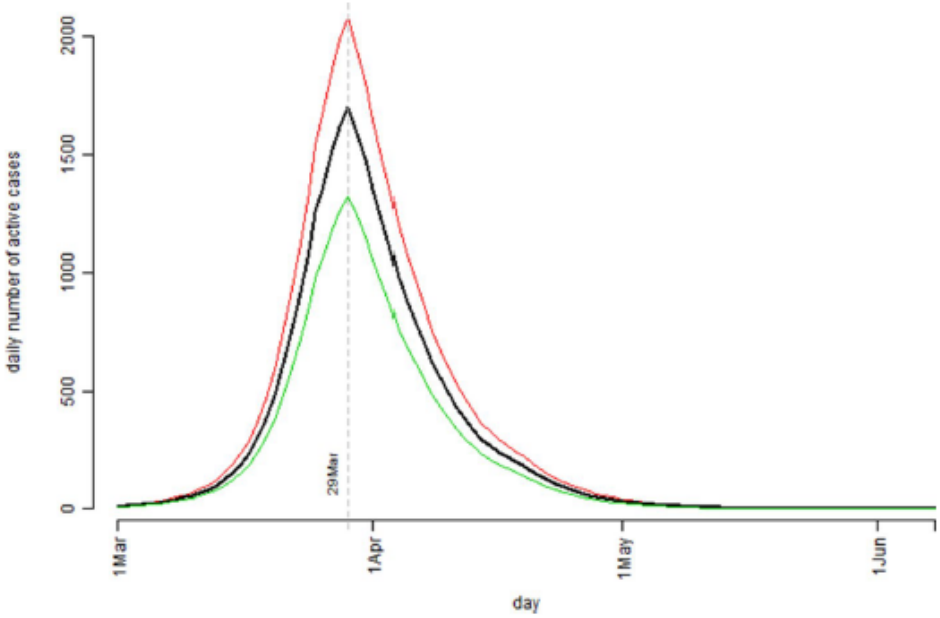

Figura 10 – *"O padrão do modelo estimou o número de casos de infecção ativa durante o período de observação com base nos dados de casos COVID-19 confirmados pela Austrália: a curva preta em negrito é a mediana, a curva verde fina é o 25 percentil e a curva vermelha fina é o 75 percentil de execuções de simulações de 1.000 passos."*

Este modelo de simulação foi considerado uma ferramenta de tomada de decisão e análise "what-if"eficaz e adaptável na luta contra o COVID-19 na necessidade imediata e para modelar quaisquer outras doenças infecciosas no futuro.

7 CONCLUSÃO

O Método de Monte Carlo é uma maneira eficaz de se lidar com os mais variados tipos de sistemas. A ideia é estimar a distribuição de uma estatística extraindo amostras aleatórias de uma população e observar o comportamento da estatística sobre as amostras. O método possui muitas aplicações e, neste trabalho o método de Monte Carlo foi utilizado para calcular o valor de π e algumas integrais.

Ao utilizar a simulação de Monte Carlo para o cálculo de integrais, obtém-se um método simples de implementar, abrangente, pois pode-se calcular integrais com quaisquer limites de integração, e adaptativo, pois o método se adapta facilmente para lidar com integrais multidimensionais.

Além disso, é interessante notar como o método é abrangente, podendo ser utilizado em diversas situações, como predição de surtos epidêmicos e valores de ativos da bolsa de valores.

REFERÊNCIAS

FLIESSBACH, Torsten; PROVIDÊNCIA JR, João da. **Curso de Física Estatística**. 2000.

KALOS MALVIN H.; WHITLOCK, Paula A. **Monte Carlo Methods**. 2008.

KRAUTH, Werner. **Statistical Mechanics: Algorithms and Computations**. 1. ed. Laboratoire de Physique Statistique, Ecole Normale Superieure, Paris: Oxford, 2006.

PEASE, Christopher. **An Overview of Monte Carlo Methods**. 2018. Disponível em: <https://towardsdatascience.com/an-overview-of-monte-carlo-methods-675384eb1694>. Acesso em: 13 mar. 2021.

WIKIPÉDIA. **Andrei Markov — Wikipédia, a enciclopédia livre**. 2021. [Online; accessed 17-janeiro-2021]. Disponível em: <https://pt.wikipedia.org/w/index.php?title=Andrei_Markov&oldid=60256717>.

WIKIPÉDIA. **Método de Monte Carlo — Wikipédia, a enciclopédia livre**. 2020. [Online; accessed 18-dezembro-2020]. Disponível em: <https://pt.wikipedia.org/w/index.php?title=M%C3%A9todo_de_Monte_Carlo&oldid=60040846>.

WIKIPEDIA CONTRIBUTORS. **Shlomo Sawilowsky — Wikipedia, The Free Encyclopedia**. 2021. [Online; accessed 18-May-2021]. Disponível em: <https://en.wikipedia.org/w/index.php?title=Shlomo_Sawilowsky&oldid=1014077859>.

WIKIPÉDIA, a enciclopédia livre. **Física Estatística**. 2018. Disponível em: <https://pt.wikipedia.org/wiki/F%C3%ADsica_estat%C3%ADstica>. Acesso em: 13 mar. 2021.

WIKIPÉDIA, a enciclopédia livre. **Mecânica Estatística**. 2020. Disponível em: <https://pt.wikipedia.org/wiki/Mec%C3%A2nica_estat%C3%ADstica>. Acesso em: 13 mar. 2021.

XIE, Gang. A novel Monte Carlo simulation procedure for modelling COVID-19 spread over time. **Nature**. Disponível em: <https://www.nature.com/articles/s41598-020-70091-1>. Acesso em: 17 mai. 2021.